

ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΩΣ ΤΜΗΜΑ ΨΗΦΙΑΚΩΝ ΣΥΣΤΗΜΑΤΩΝ

Πρόγραμμα Μεταπτυχιακών Σπουδών:

«Πληροφοριακά Συστήματα & Υπηρεσίες»

ΜΑΘΗΜΑ: Μηχανική Μάθηση: Μέθοδοι και Αλγόριθμοι

ΤΙΤΛΟΣ : Εργασίας Χειμερινού Εξαμήνου 2025-2026

Φοιτητής: Χρήστος Τσάμης ΑΜ: me25038

Διδάσκων: Ο. Τελέλης

ΠΕΙΡΑΙΑΣ, 2026

Περιεχόμενα

1. Εισαγωγή (Ανάλυση της αναφοράς) 2
2. ΜΕΡΟΣ Α: Ανάλυση Δημοπρασιών eBay 2
2.1. Εισαγωγή & Προεπεξεργασία (Data Preprocessing) 2
2.2. Πρόβλημα Παλινδρόμησης 3
2.3 Πρόβλημα Κατηγοριοποίησης 6
2.4 Πρόβλεψη Ανταγωνιστικότητας (Binary Classification) 10
3. ΜΕΡΟΣ Β: Κατηγοριοποίηση Εικόνων CIFAR-10 12
3.1. Εισαγωγή και Περιγραφή Δεδομένων 12
3.2. Μεθοδολογία & Προεπεξεργασία (Feature Extraction) 12
3.3.Μοντέλα Κατηγοριοποίησης 13
3.4 Τελικά συμπεράσματα 18
5. Βιβλιογραφία - Αναφορές 19

1. Εισαγωγή (Ανάλυση της αναφοράς)

Η αναφορά αυτή αποτελεί μια επεξήγηση της εργασίας για το μάθημα Μηχανική Μάθηση: Μέθοδοι και Αλγόριθμοι . Η εργασία χωρίζεται σε δύο μέρη ,το μέρος Α που αφορά την ανάλυση δημοπρασιών eBay και το μέρος Β την κατηγοριοποίηση εικόνων από το σύνολο CIFAR-10. Το μέρος Α αποσκοπεί στην πρόβλεψη τιμής δημοπρασιών (Regression), την πρόβλεψη πώλησης η όχι ενός αντικειμένου (Classification) και την πρόβλεψη εάν η τελική τιμή πώλησης του αντικειμένου ξεπεράσει τον μέσο όρο της αγοράς (Classification).Το μέρος Β αποσκοπεί στην κατηγοριοποίηση όλων των κλάσεων των εικόνων με χρήση κλασικών μεθόδων machine learning, αλλά και στην σύγκριση pre processed τεχνικών μηχανικής όρασης. Σε κάθε μέρος αναλύεται η μεθοδολογία που ακολουθήθηκε, καθώς και τα συμπεράσματα των αποτελεσμάτων.

2. ΜΕΡΟΣ Α: Ανάλυση Δημοπρασιών eBay

2.1. Εισαγωγή & Προ επεξεργασία (Data Preprocessing)

Τα δεδομένα ήταν χωρισμένα σε 2 set για τα διαφορετικά προβλήματα που κληθήκαμε να αντιμετωπίσουμε[1]. Τα set αυτά με την σειρά τους ήταν χωρισμένα σε training και test set, παρόλα αυτά ενοποιήθηκαν και χωρίστηκαν ξανά με σκοπό την εξασφάλισή της σωστής κατανομής των δεδομένων αλλά και της αμεροληψίας της αξιολόγησης. Ο διαχωρισμός που ακολουθήθηκε ήταν 60% training set, 20% test set και 20% validation set.

Έπειτα από επισκόπηση και έλεγχο των δεδομένων δεν εμφανίστηκαν κενές τιμές. Το μόνο χαρακτηριστικό που εμφάνισε “προβληματικές” τιμές ήταν το *hit count* που είχε αρνητικές τιμές κάτι αδύνατο. Μιας και είναι ένα “μελλοντικό” χαρακτηριστικό δεν επεξεργάστηκαν οι αρνητικές τιμές καθώς δεν θα χρησιμοποιηθούν πουθενά.

Οι μεταβλητές *seller name* και *end day* κρίθηκε ότι περιέχουν σημαντική πληροφορία οπότε εφαρμόστηκε Target encoding ώστε να μπορεί να αξιοποιηθεί. Συγκεκριμένα ,το *seller name* αντικαταστάθηκε με τον μέσο όρο τιμής πώλησης και με το ποσοστό επιτυχίας στις πωλήσεις, που είχε πετύχει πωλητής στο training set (ώστε να αποφευχθεί data leakage). Το *end day* είναι πληροφορία που ορίζεται στην αρχή της δημοπρασίας (πότε λήγει) οπότε μπορούμε να το

χρησιμοποιήσουμε άφοβα στα μοντέλα μας. Κάποιες μέρες υπάρχει μεγαλύτερη επισκεψιμότητα, ως αποτέλεσμα οι τιμές γίνονται πιο ανταγωνιστικές.

Όσον αφορά το πρόβλημα πρόβλεψης τιμής, λόγω της μεγάλης ασυμμετρίας (skewness) στην κατανομή των τιμών, εφαρμόστηκε λογαριθμικός μετασχηματισμός **(Log(1+Price))** στον στόχο του regression(Price) κατά την εκπαίδευση, ώστε να ομαλοποιηθεί η κατανομή και να περιοριστεί η επίδραση των ακραίων τιμών (outliers). Επιπλέον έγινε κανονικοποίηση φέρνοντας όλα τα δεδομένα στην ίδια κλίμακα **(StandardScaler)**, κάτι απαραίτητο για τα μοντέλα k-NN και SVR.

Αντίστοιχα για το πρόβλημα της κατηγοριοποίησης εφαρμόστηκε μόνο η κανονικοποίηση φέρνοντας τα δεδομένα στην ίδια κλίμακα μέσω του **(StandardScaler)** για τον αλγόριθμο Logistic Regression.

Τέλος πραγματοποιήθηκε έλεγχος δυναμικότητας σε διάφορες μεταβλητές που αφορούν το ιστορικό πωλήσεων ώστε να διαπιστωθεί εάν τα στατιστικά αυτά υπολογίστηκαν σε ολόκληρο το dataset,άρα προσφέρουν μελλοντική πληροφορία και πρέπει να αφαιρεθούν από τα μοντέλα. Άλλωστε η πληροφορία για την "ποιότητα" του πωλητή υπάρχει μέσω του target encoding που εφαρμόσαμε παραπάνω.

2.2. Πρόβλημα Παλινδρόμησης

Για το πρόβλημα παλινδρόμησης σκόπιμο κρίθηκε να "κρατηθούν" τα ακόλουθα χαρακτηριστικά, που δεν περιέχουν μελλοντική πληροφορία:

Category, StartingBid, Authenticated, ReturnsAccepted, IsHOF, Seller_Avg_Price (προήλθε από το target encoding), Day_Avg_Price (προήλθε από το target encoding)

Επιλέχθηκαν 3 μοντέλα για έλεγχο

1. Polynomial Ridge:Γραμμικό μοντέλο με πολυωνυμικά χαρακτηριστικά (Baseline).
2. k-NN Regressor:Μοντέλο γειτνίασης.
3. SVR (Support Vector Regression):Μοντέλο διανυσμάτων υποστήριξης (χρησιμοποιήθηκε δείγμα 20.000 δεδομένων για ταχύτητα).

Ακολουθούν τα αποτελέσματα τους όσων αφορά το RMSE(μέσο τετραγωνικό σφάλμα) και το MedAE (Διάμεση Απόλυτη Απόκλιση) συγκεντρωτικά:

Μοντέλο	**RMSE**
Polynomial Ridge	39.03
k-NN Regressor (k=50)	29.38
SVR (RBF Kernel)	31.80

Μοντέλο	MedAE
Polynomial Ridge	5.81
k-NN Regressor (k=50)	3.78
SVR (RBF Kernel)	4.35

Είναι εμφανές ότι ο k-NN Regressor απέδωσε καλύτερα από τα άλλα δύο μοντέλα, οπότε το εφαρμόζουμε και στο test set που δεν έχει χρησιμοποιηθεί καθόλου μέχρι στιγμής και περιέχει τελείως άγνωστα δεδομένα για το μοντέλο.

Για τη μεγιστοποίηση της απόδοσης του αλγορίθμου k-NN, εφαρμόστηκε η μέθοδος **Grid Search** με 5-πλή επικύρωση (5-fold Cross Validation). Στόχος ήταν η εύρεση του βέλτιστου συνδυασμού παραμέτρων που ελαχιστοποιεί το σφάλμα πρόβλεψης, αποφεύγοντας παράλληλα την υπερπροσαρμογή (overfitting).

Συγκεκριμένα εξετάστηκαν:

- **Πλήθος Γειτόνων (n_neighbors):** Δοκιμάστηκε εύρος τιμών από **10 έως 50**. Οι μικρές τιμές επιτρέπουν την προσαρμογή σε τοπικά χαρακτηριστικά, ενώ οι μεγαλύτερες (π.χ. 30, 40,50) προσφέρουν εξομάλυνση του θορύβου και των ακραίων τιμών (outliers).
- **Στάθμιση (weights):** Συγκρίθηκε η **'uniform'** (όπου όλοι οι γείτονες έχουν ίση βαρύτητα) έναντι της **'distance'** (όπου οι κοντινότεροι γείτονες επηρεάζουν περισσότερο την τιμή). Η 'distance' αναμένεται να αποδώσει καλύτερα λόγω της φύσης των δεδομένων δημοπρασίας (τα παρόμοια αντικείμενα έχουν παρόμοιες τιμές).
- **Μετρική Απόστασης (metric):** Εξετάστηκαν οι αποστάσεις **Euclidean** και **Manhattan**, για να διαπιστωθεί ποια γεωμετρία ταιριάζει καλύτερα στον χώρο των χαρακτηριστικών μας.

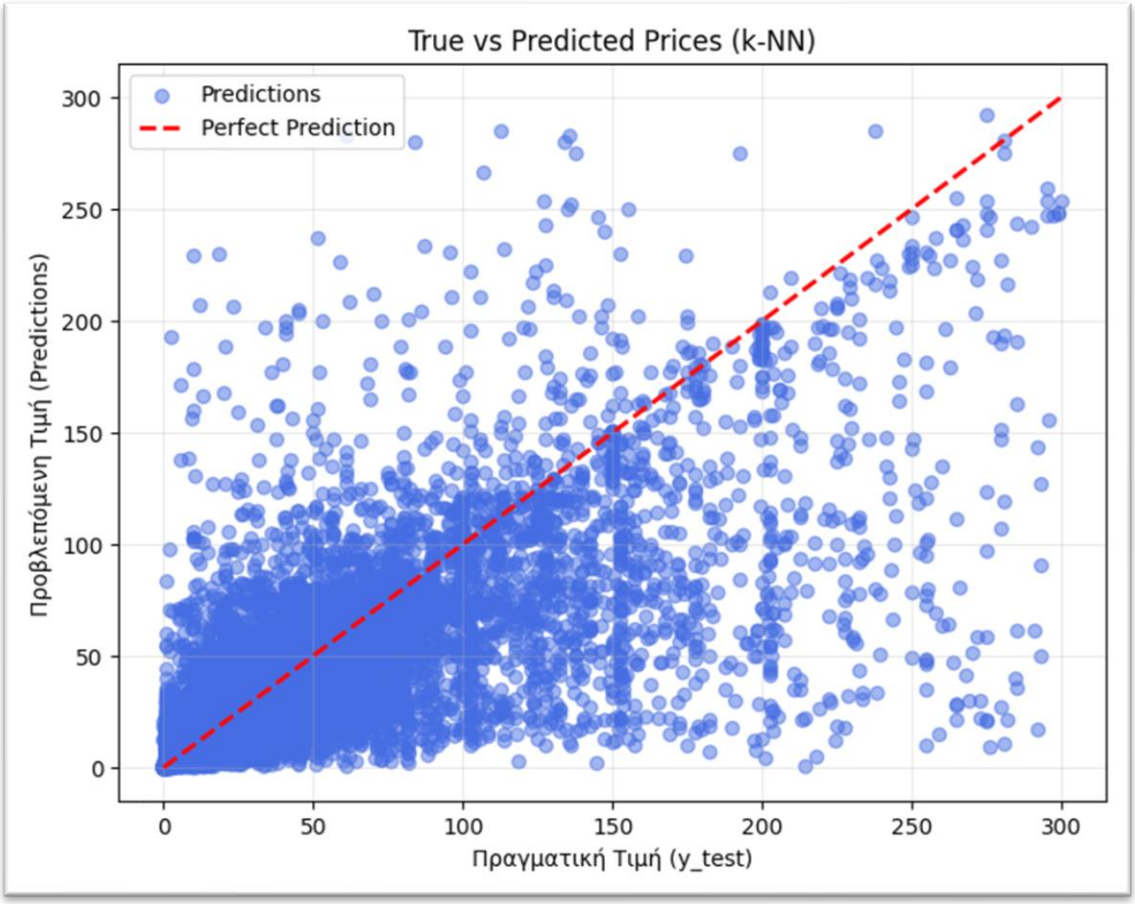
Το βέλτιστο μοντέλο που προέκυψε είχε τα εξής χαρακτηριστικά **metric=euclidean, n_neighbors=50, weights=distance** τα οποία χρησιμοποιήθηκαν για την τελική αξιολόγηση στο Test Set.

Τελικά Αποτελέσματα:

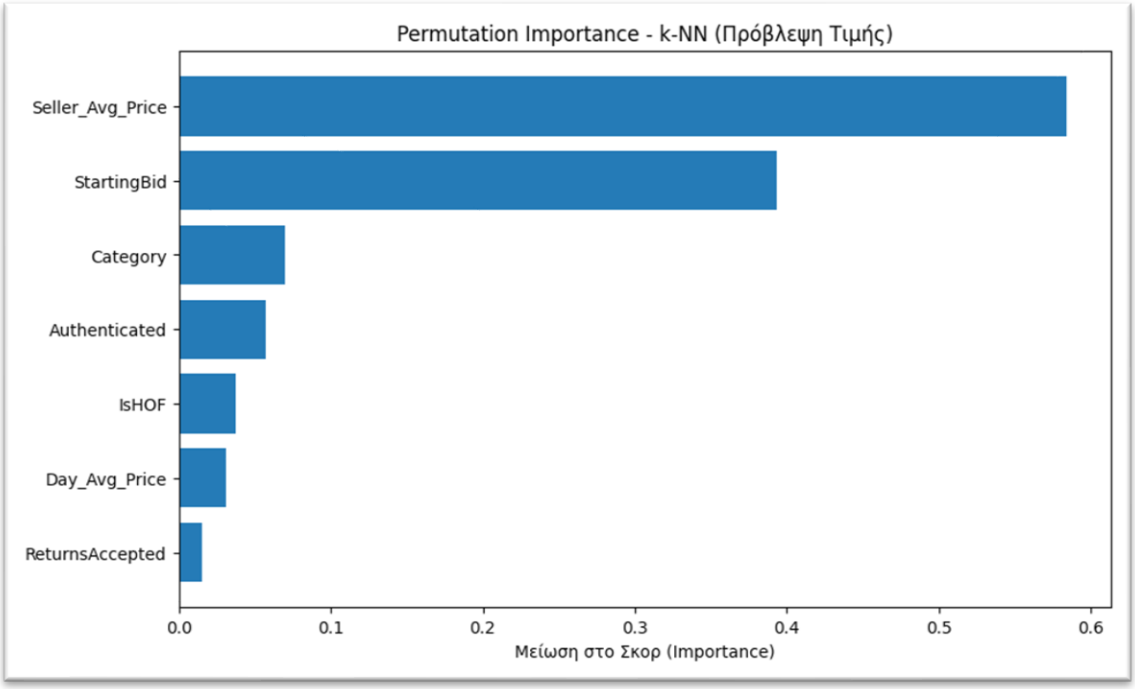
- **R^2(Συντελεστής Προσδιορισμού): 0.5883** Το μοντέλο ερμηνεύει επιτυχώς το 58.8% της διακύμανσης των τιμών, ποσοστό ιδιαίτερα υψηλό για δεδομένα με έντονο ανθρώπινο παράγοντα.
- **RMSE (Επηρεάζεται από τα ακριβά): 29.386** Η τιμή αυτή είναι υψηλή (σχεδόν συγκρίσιμη με τη μέση τιμή των 32.60€), γεγονός που οφείλεται στην ευαισθησία του δείκτη RMSE στις ακραίες τιμές (outliers).
- **MAE (Μέσο Απόλυτο Σφάλμα): 13.3312**

- **MedAE (Σφάλμα στη διάμεσο): 3.7842** . Αυτός είναι ο πιο αντιπροσωπευτικός δείκτης για την ακρίβεια του μοντέλου. Δεδομένου ότι η διάμεση τιμή των προϊόντων είναι 14.99, το σφάλμα των 3.78 μονάδων υποδεικνύει ότι για την πλειοψηφία των "τυπικών" δημοπρασιών, η πρόβλεψη είναι εξαιρετικά ακριβής.

Συμπέρασμα: Η μεγάλη διαφορά μεταξύ RMSE (29.386) και MedAE (3.7842) επιβεβαιώνει τη θετική ασυμμετρία (positive skewness) των δεδομένων. Το μοντέλο είναι πολύ αξιόπιστο για τη συντριπτική πλειοψηφία των αντικειμένων χαμηλής και μεσαίας αξίας, ενώ τα μεγαλύτερα σφάλματα εντοπίζονται αποκλειστικά σε σπάνια, υψηλής αξίας συλλεκτικά αντικείμενα, τα οποία είναι εγγενώς πιο δύσκολο να προβλεφθούν καθώς δεν έχουμε κάποια μεταβλητή που να προσδιορίζει την σπανιότητα του αντικειμένου η την κατάσταση του.



Τέλος ενδιαφέρον είχε να ελέγξουμε ποιο χαρακτηριστικό είχε το μεγαλύτερο βάρος για την πρόβλεψη τιμής στο k-nn. Εφαρμόζοντας Permutation Importance πήραμε τα εξής αποτελέσματα που αναδεικνύουν την σημαντικότητα του target encoding που εφαρμόσαμε στο seller name.



2.3 Πρόβλημα Κατηγοριοποίησης

Στόχος μας σε αυτό το πρόβλημα είναι η πρόβλεψη του εάν ένα προϊόν θα πουληθεί ή όχι (Binary Classification). Επιλέχθηκαν τα εξής χαρακτηριστικά, με προσοχή ώστε να αποφευχθεί η χρήση μελλοντικής πληροφορίας (data leakage) από το μοντέλο:

'Category', 'StartingBid', 'ReturnsAccepted', 'IsHOF', 'ItemListedCount', 'Seller_Success_Rate'(αποτέλεσμα του target encoding που κάναμε στο training set), 'Day_Success_Rate'(αποτέλεσμα του target encoding που κάναμε στο training set)

Ελέγχθηκαν 2 μοντέλα κατηγοριοποίησης: Logistic Regression (ως baseline) και Random Forest. Λόγω της ανισορροπίας των κλάσεων (70% Όχι - 30% Ναι), εφαρμόστηκε εξισορρόπηση των βαρών (class_weight='balanced') και στα δύο μοντέλα, ώστε να μεγιστοποιηθεί η ικανότητα εντοπισμού των πωλήσεων (Recall).

Τα συγκριτικά αποτελέσματα στο Test Set συνοψίζονται στον παρακάτω πίνακα:

Μοντέλο	Accuracy	F1-Score
Logistic Regression	0.8066	0.6882
Random Forest	0.8244	0.7175

Η μετρική **F1-Score** έχει μεγαλύτερη βαρύτητα από το **Accuracy** καθώς μας δείχνει την πραγματική απόδοση του μοντέλου στην εν λόγω ανισόρροπη κατανομή δεδομένων. Σε αντίθεση με το **Accuracy**, που μπορεί να είναι παραπλανητικό, το **F1-Score** συνδυάζει την **Ακρίβεια (Precision)** και την **Ανάκληση (Recall)**, επιτρέποντάς μας να αξιολογήσουμε πόσο αποτελεσματικά το μοντέλο εντοπίζει τις πωλήσεις (μειοψηφούσα κλάση), το οποίο αποτελεί και τον κύριο επιχειρηματικό στόχο. Με αυτό σαν γνώμονα τα αποτελέσματα του RandomForest είναι καλύτερα από του Logistic Regression κάτι που ήταν αναμενόμενο.

Για τη μεγιστοποίηση της απόδοσης του Random Forest, εφαρμόστηκε η μέθοδος **Grid Search** με 5-πλή επικύρωση **(5-fold Cross Validation)**. Στόχος ήταν η εύρεση του βέλτιστου συνδυασμού παραμέτρων που ελαχιστοποιεί το σφάλμα πρόβλεψης, αποφεύγοντας παράλληλα την υπερπροσαρμογή (overfitting).

Συγκεκριμένα εξετάστηκαν:

- **n_estimators (Πλήθος Δέντρων):** Ελέγξαμε αν η αύξηση των δέντρων βελτιώνει τη σταθερότητα του μοντέλου ή αν φτάνουμε σε σημείο κορεσμού. Οι τιμές που ελέγχθηκαν ήταν **100** και **200**.
- **max_depth (Μέγιστο Βάθος):** Ρυθμίζει την πολυπλοκότητα. Μικρό βάθος (π.χ.10) μπορεί να οδηγήσει σε υπο-εκμάθηση (underfitting), ενώ απεριόριστο (None) σε αποστήθιση (overfitting). Οι τιμές που ελέγχθηκαν ήταν **10, 20** και **None**.
- **min_samples_leaf (Ελάχιστα δείγματα ανά φύλλο):** Η πιο κρίσιμη παράμετρος για την αποφυγή του θορύβου. Υποχρεώνει το δέντρο να παίρνει αποφάσεις βασισμένο σε ομάδες δειγμάτων και όχι σε μεμονωμένες περιπτώσεις. Οι τιμές που ελέγχθηκαν ήταν **1, 2** και **4**.

Ερμηνεία των Βέλτιστων Τιμών (depth=20, leaf=4):

- Η επιλογή του **max_depth=20** (αντί για None) δείχνει ότι το μοντέλο χρειαζόταν περιορισμό στο βάθος για να μην γίνει υπερβολικά περίπλοκο και να γενικεύει καλύτερα.
- Η επιλογή του **min_samples_leaf=4** (αντί για 1) ήταν καθοριστική. Ανάγκασε το μοντέλο να αγνοήσει τις πολύ σπάνιες/ακραίες περιπτώσεις (outliers) και να μάθει πιο γενικούς κανόνες. Αυτό εξηγεί γιατί πέτυχες τόσο υψηλό **Precision (0.80)** και **Accuracy (84%)**, καθώς το μοντέλο έγινε πιο "αυστηρό" και αξιόπιστο.

Στην συνέχεια ο αλγόριθμος εφαρμόστηκε στο test set για την τελική αξιολόγηση και εξήχθησαν τα εξής αποτελέσματα.

Κλάση	Precision	Recall	F1-Score	Πλήθος (Support)
0 (Not Sold)	0.88	0.86	0.87	41,520
1 (Sold)	**0.69**	**0.74**	**0.72**	**17,690**
Weighted Avg	0.83	0.82	0.83	59,210

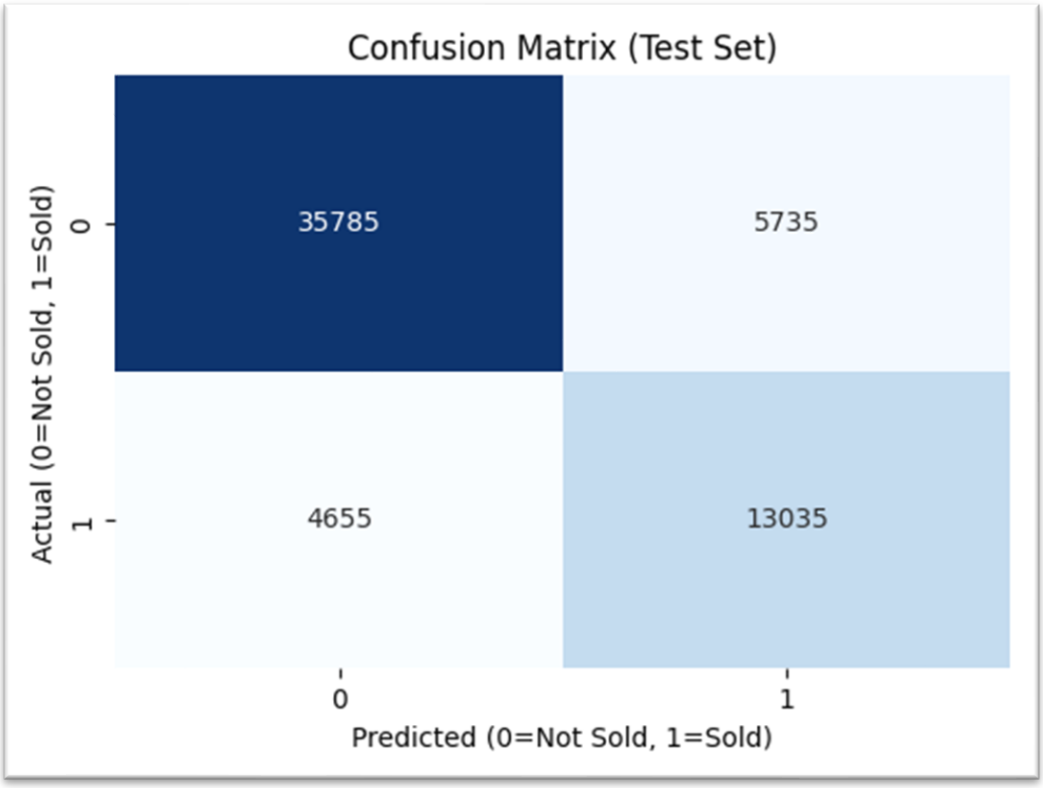
Final Test Accuracy: 0.8245

ROC-AUC Score: 0.8732

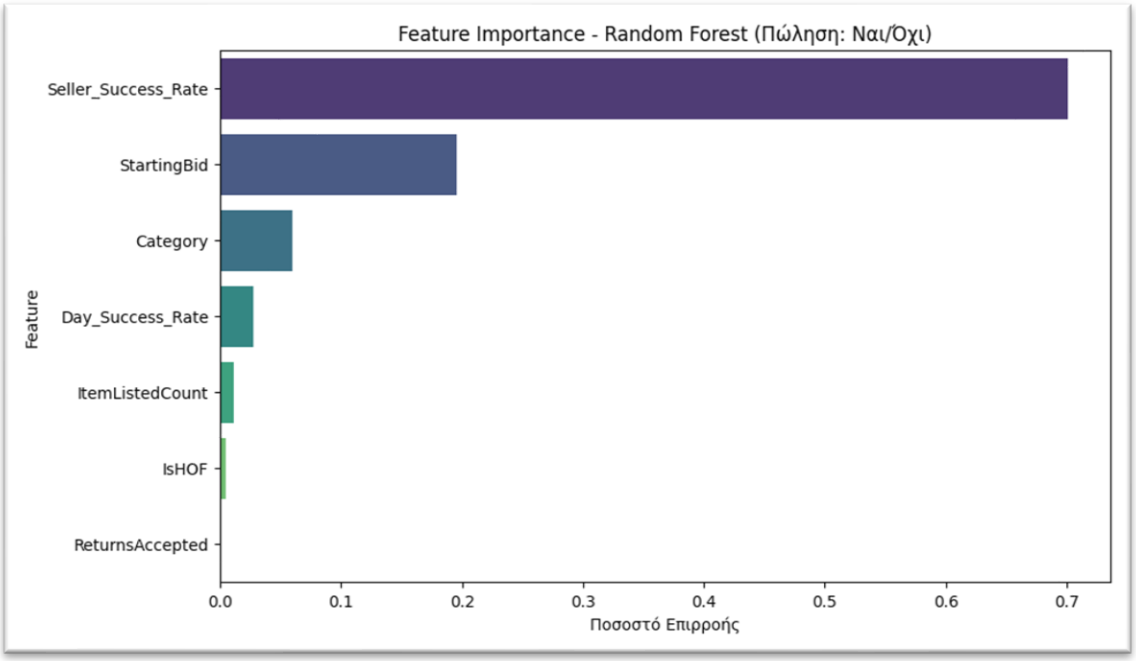
Συμπέρασμα: Το μοντέλο Random Forest επέδειξε υψηλή στιβαρότητα, επιτυγχάνοντας συνολική ακρίβεια **82.32%** και εξαιρετική διαχωριστική ικανότητα (**ROC-AUC 0.87**).

Το σημαντικότερο εύρημα αφορά την κλάση-στόχο («Sold»), όπου επιτεύχθηκε **Recall 74%**. Αυτό σημαίνει ότι ο αλγόριθμος εντοπίζει επιτυχώς σχεδόν τα **3 στα 4** προϊόντα που πρόκειται να πουληθούν, ελαχιστοποιώντας τις χαμένες ευκαιρίες πώλησης. Παράλληλα, το **F1-Score (0.71)** καταδεικνύει ότι η εξισορρόπηση των βαρών λειτούργησε αποτελεσματικά, επιτρέποντας αξιόπιστες προβλέψεις παρά την ανισορροπία των δεδομένων.

Παρατηρόντας το **Precision 69%** στην κλάση-στόχο βλέπουμε ότι το μοντέλο μας είναι “αισιόδοξο” προβλέποντας πώληση σε αντικείμενα που τελικά δεν πουλήθηκαν. Αυτό είναι αναμενόμενο καθώς τα χαρακτηριστικά που έχουμε (τιμή και πωλητής) μπορεί να είναι ιδανικά για μια πώληση παρόλαυτα άλλες πληροφορίες για την κατάσταση του προϊόντος, τις οποίες δεν έχουμε, θα μπορούσαν να δείχνουν προς μια άλλη κατεύθυνση.



Παρόμοια με το Regression ελέγχοντας ποιο χαρακτηριστικό είχε την μεγαλύτερη επιρροή βλέπουμε ότι το **seller success rate** που δημιουργήσαμε είχε την μεγαλύτερη σημαντικότητα. Θα μπορούσε αυτή η σύγκριση των χαρακτηριστικών να γίνει και μέσω ενός απλού δέντρου απόφασης που λειτουργεί σαν white box.



2.4 Πρόβλεψη Ανταγωνιστικότητας (Binary Classification)

Στο τελευταίο πρόβλημα ανάλυσης δημοπρασιών καλούμαστε να προβλέψουμε την ποιότητα της πώλησης, το οποίο είναι ένα νέο πρόβλημα κατηγοριοποίησης.

Εφόσον εισήχθησαν τα σωστά δεδομένα πωλήσεων δημιουργήθηκε μια νέα μεταβλητή στόχος. Η μεταβλητή αυτή ελέγχει εάν ο μέσος όρος του αντικειμένου είναι πάνω από την τιμή που πουλήθηκε το συγκεκριμένο αντικείμενο. Το 70% των τελικών τιμών των προϊόντων είναι κάτω από τον μέσο όρο, κάτι που είναι απόλυτα φυσιολογικό καθώς μερικά πολύ ακριβά αντικείμενα ανεβάζουν τον μέσο όρο ως αποτέλεσμα η πλειοψηφία των αντικειμένων είναι κάτω από αυτόν. Αυτή η ανισορροπία θα αντιμετωπιστεί με το **class_weight='balanced'** όπως και προηγουμένως. Επιλέχθηκαν τα ίδια χαρακτηριστικά που επιλέχθηκαν και για το πρόβλημα του Regression ώστε να μην υπάρχει κάποια μελλοντική πληροφορία.

Υπενθύμηση χαρακτηριστικών : Category, StartingBid, Authenticated, ReturnsAccepted, IsHOF, Seller_Avg_Price, Day_Avg_Price

Τα μοντέλα που επιλέχθηκαν παραμένουν το Logistic Regression(με κανονικοποίηση) και το Random Forest

Τα οποία έδωσαν τα ακόλουθα αποτελέσματα :

Μοντέλο	Accuracy	Precision (Class 1)	Recall (Class 1)	F1-Score (Class 1)
Logistic Regression	0.6503	0.45	0.51	0.48
Random Forest	0.7067	0.53	0.64	0.58

Εφαρμόζοντας το Random Forest στο test set για να πάρουμε τα τελικά μας αποτελέσματα ,έχουμε:

Κλάση	**Περιγραφή**	**Precision**	**Recall**	**F1-Score**	**Πλήθος (Support)**
0	Τιμή < Μ.Ο. (Φθηνά)	0.82	0.74	0.78	12,415
1	Τιμή >= Μ.Ο. (Ακριβά)	**0.51**	**0.63**	**0.56**	5,410
Σύνολο	Weighted Avg	0.73	0.71	0.71	17,825

Final Accuracy: 70.63%

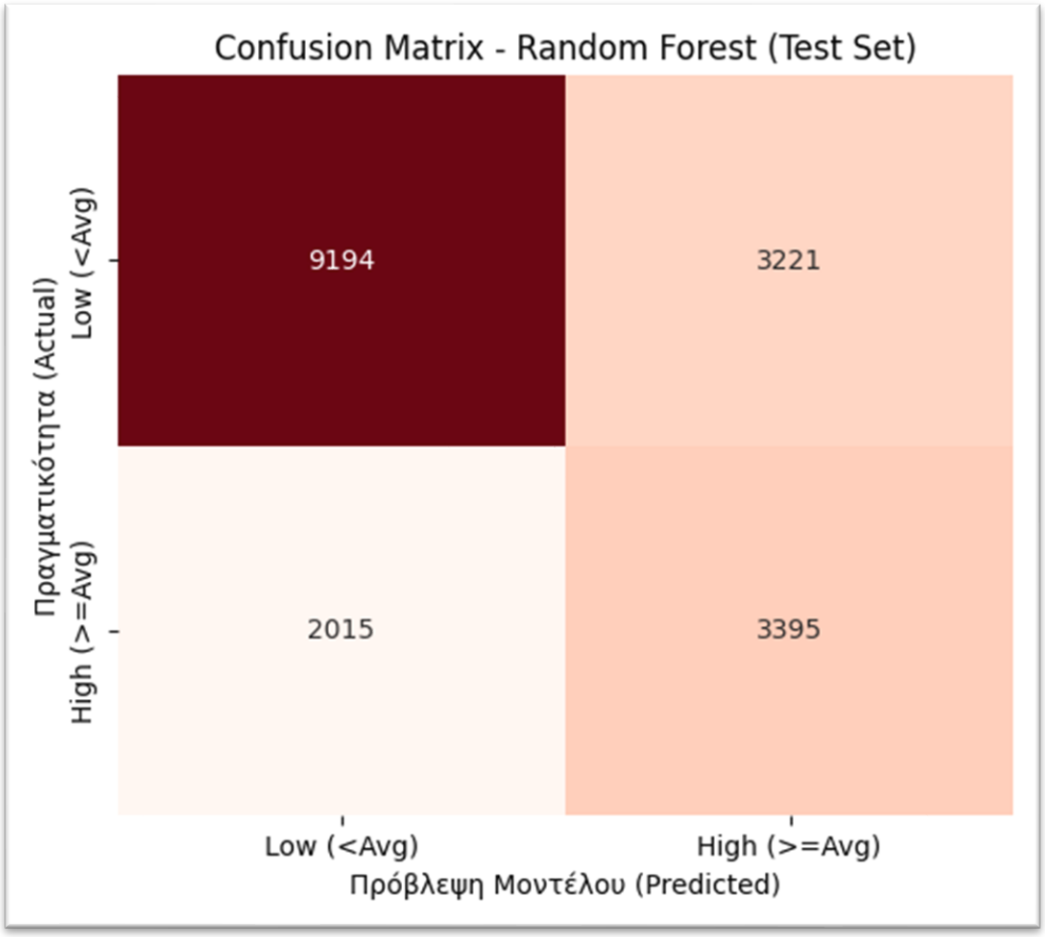
Baseline Accuracy: 69.65% (Αν επιλέγαμε τυχαία την πλειοψηφία)

Συμπέρασμα:

Στο συγκεκριμένο πρόβλημα, τα δεδομένα είναι ανισόρροπα, με την "ακριβή" κλάση (1) να αποτελεί μόλις το 30%. Αυτό σημαίνει ότι ένα απλοϊκό μοντέλο που θα προέβλεπε συνεχώς την πλειοψηφούσα κλάση (0), θα πετύχαινε αυτομάτως ακρίβεια 70%.

Συνεπώς, η συνολική ακρίβεια του **Random Forest (70.63%)** δεν αποτελεί το κύριο κριτήριο επιτυχίας. Η πραγματική αξία του μοντέλου βρίσκεται στο **Recall** της μειοψηφούσας κλάσης **(63%)**. Κατάφερε να εντοπίσει με επιτυχία την πλειοψηφία των "ακριβών" προϊόντων, ξεπερνώντας τη δυσκολία της ανισορροπίας.

Παρόλα αυτά, το χαμηλό **Precision (~51%)** μας δείχνει ότι το μοντέλο μας είναι αρκετά “αισιόδοξο” προβλέποντας αρκετά false positives. Αυτό συμβαίνει για δύο λόγους. Αρχικά χρησιμοποιώντας το **class_weight='balanced'** αυξάνουμε το Recall στον εντοπισμό ακριβών αντικειμένων μειώνοντας αναπόφευκτα το Precision του. Επιπλέον, απουσιάζει η πληροφορία των περιγραφικών χαρακτηριστικών του αντικειμένου π.χ. κατάσταση φθοράς , αισθητική της εικόνας του , κατι που εμποδίζει το μοντέλο να διακρύνει εάν το αντικείμενο θα κινηθεί πάνω ή κάτω από τον μέσο όρο. Το μοντέλο βασίζεται κυρίως στη φήμη του πωλητή και την τιμή εκκίνησης, τα οποία αποτελούν ισχυρές ενδείξεις αλλά δεν εγγυώνται πάντα υψηλή τελική τιμή.



---

3. ΜΕΡΟΣ Β: Κατηγοριοποίηση Εικόνων CIFAR-10

3.1. Εισαγωγή και Περιγραφή Δεδομένων

Στο Β μέρος της εργασίας θα ασχοληθούμε με την κατηγοροιοποίηση εικόνων 32x32 pixel σε **10 κλάσεις** (αεροπλάνο , αυτοκίνητο, σκύλος, γάτα κλπ.)[2].Το συγκεκριμένο σύνολο δεδομένων είναι αρκετά σύνθετο καθώς οι εικόνες έχουν περίπλοκο φόντο και μεγάλη ποικιλομορφία εντός των κλάσεων.

3.2. Μεθοδολογία & Προεπεξεργασία (Feature Extraction)

Για την εξασφάλιση της γρήγορης εκτέλεσης φορτώθηκαν **3 batch** (30.000 εικόνες) από εικόνες όπως και το **test batch** (10.000 εικόνες). Όλες οι εικόνες ενώθηκαν και ξαναχωρίστηκαν σε **20.000** για το **training set** και **4.000** για το **test set**. Κρατήθηκε η αναλογία 1:5 test και training set που είχαν το σύνολο των δεδομένων. Ο χωρισμός των δεδομένων έγινε μέσω **Stratified Split** ώστε όλες οι κλάσεις να έχουν τον ίδιο αριθμό δειγμάτων.

Στην συνέχεια για την εξαγωγή πληροφορίας από τις εικόνες χρησιμοποιήθηκαν 2 μεθοδολογίες:

- Η πρώτη μεθοδολογία ονομάζεται **HOG (Histogram of Oriented Gradients) [3]** και ουσιαστικά εξάγει τα σχήματα των εικόνων. Μέσω των παραμέτρων **pixels_per_cell=(8, 8), orientations=9** σπάει τις εικόνες σε μικρά τετράγωνα ώστε να βρει την κατεύθυνση των ακμών, λειτουργώντας ωστόσο σε κλίμακα του γκρι.
- Η δεύτερη μεθοδολογία ονομάζεται **Ιστογράμματα Χρώματος (Color Histograms)** η οποία ξεχωρίζει τα αντικείμενα με βάση το χρώμα τους σε αντίθεση με το HOG που δουλεύει σε ασπρόμαυρη κλίμακα

Τα χαρακτηριστικά που εξήχθησαν από τις δύο μεθόδους συνενώθηκαν σε ένα ενιαίο διάνυσμα για κάθε εικόνα αυξάνοντας τον συνολικό αριθμό. Λόγω του μεγάλου αριθμού χαρακτηριστικών που προέκυψαν, εφαρμόστηκε **PCA (Principal Component Analysis)** διατηρώντας το 90% της πληροφορίας, ώστε να μειωθούν οι διαστάσεις και να επιταχυνθεί η εκπαίδευση χωρίς σημαντική απώλεια ακρίβειας.

Αριθμός χαρακτηριστικών

	Χωρίς PCA	Με PCA
HOG	324	98
HOG + COLOR	440	138

Σημειώνεται ότι η PCA είναι ευαίσθητη στην κλίμακα των τιμών οπότε πριν την εφαρμογή της πραγματοποιήθηκε **κανονικοποίηση** στα δεδομένα.

3.3.Μοντέλα Κατηγοριοποίησης

Τα μοντέλα μελετήθηκαν με διάφορους συνδυασμούς των τεχνικών προ επεξεργασίας για να διαπιστωθεί η επίδραση της εκάστοτε τεχνικής.

3.3.1 Support Vector Machine (SVM)

Το πρώτο μοντέλο που δοκιμάστηκε είναι το SVM. Ως αλγόριθμος που προσπαθεί να βρει το βέλτιστο επίπεδο διαχωρισμού (υπερεπίπεδο), λειτούργησε ικανοποιητικά δεδομένης της πολυπλοκότητας, εκμεταλλευόμενο τη μείωση θορύβου που προσέφερε η PCA.

Για την βελτιστοποίηση των παραμέτρων χρησιμοποιήθηκε η διαδικασία **Grid Search** με **Cross Validation (CV=3)** στα δεδομένα με **HOG+Color**.

Εξετάστηκαν οι παράμετροι:

- **C (Ποινή):** 1, 10, 15, 50, 100

- **gamma:** 'scale', 0.01

Οι βέλτιστες παραμέτροι αναδείχθηκαν η τιμή **C=15**, η οποία επιβάλλει αυστηρότερη ποινή στα σφάλματα ταξινόμησης σε σχέση με την προεπιλογή (default), αναγκάζοντας το μοντέλο να δημιουργήσει πιο σύνθετα όρια απόφασης. Η ρύθμιση **gamma='scale'** βοήθησε στην προσαρμογή της εμβέλειας του πυρήνα με βάση τη διακύμανση των χαρακτηριστικών.

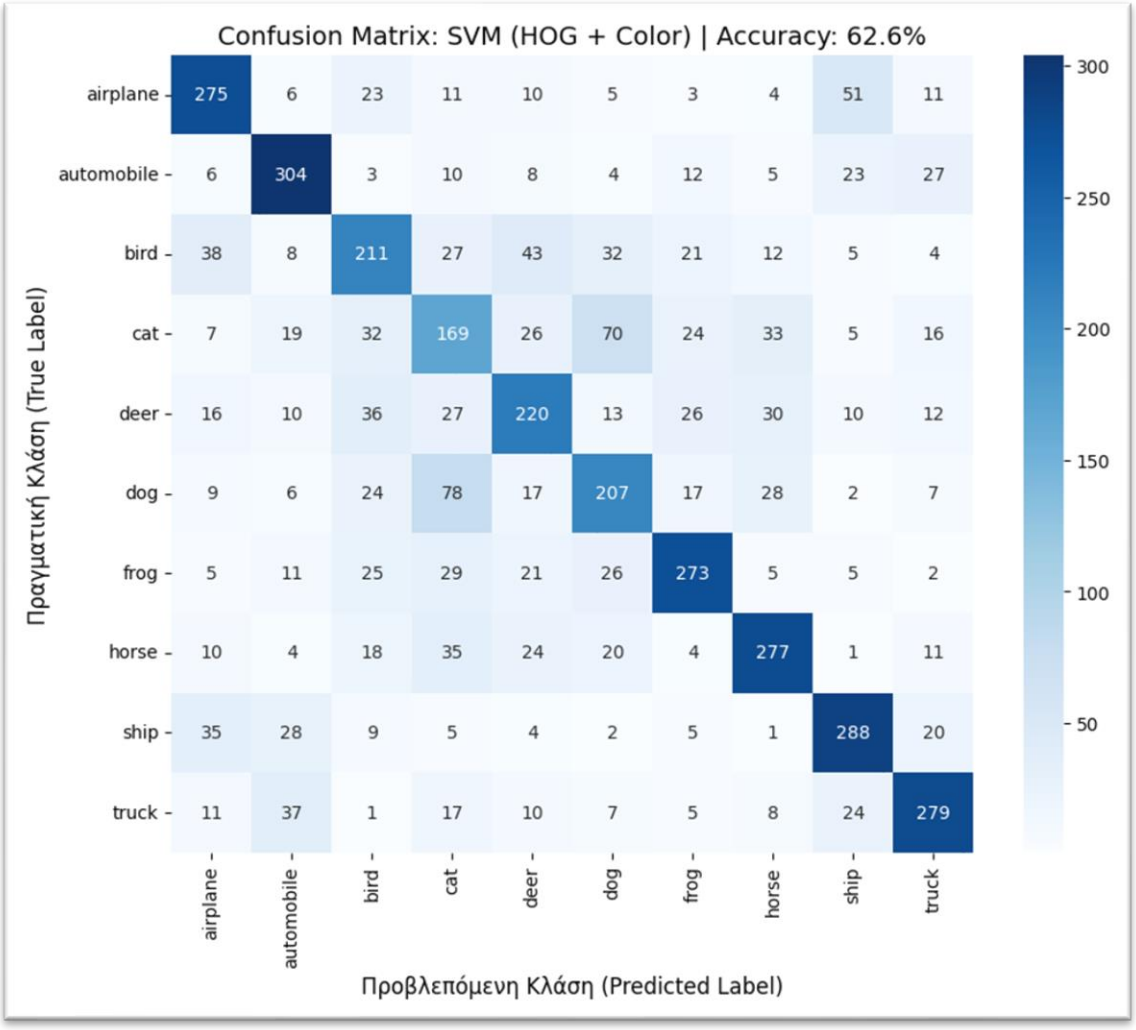
Ως εκ τούτου, το μοντέλο πέτυχε **Accuracy 59,58%** με τη χρήση μόνο **HOG**, ενώ ενσωματώνοντας την πληροφορία χρώματος η ακρίβεια αυξήθηκε στο **62,58%.**

Κατηγορία	Κλάση (Class)	Precision	Recall	F1-Score	Παρατηρήσεις
Υψηλότερη Επίδοση	**Automobile**	0.70	0.76	**0.73**	Ξεκάθαρο γεωμετρικό σχήμα.
	Ship	0.70	0.73	**0.71**	Βοηθάει το μπλε φόντο (θάλασσα/ουρανός).
	Truck	0.72	0.70	**0.71**	Παρόμοιο με Automobile, διακριτό σχήμα.
Χαμηλότερη Επίδοση	**Cat**	0.41	0.42	**0.42**	Σύγχυση με Dog (παρόμοια ανατομία).
	Dog	0.54	0.52	**0.53**	Σύγχυση με Cat.
	Bird	0.55	0.53	**0.54**	Ποικιλομορφία σχήματος και φόντου.
Σύνολο	**Weighted Avg**	**0.62**	**0.63**	**0.63**	-

Το μοντέλο τα πάει εξαιρετικά σε οχήματα (Automobile, Truck, Ship) όπου το σχήμα (HOG) και το χρώμα (Color Histograms) είναι πολύ διακριτά.

"Υποφέρει" στα ζώα, και ειδικά στη Γάτα (0.42), η οποία έχει το χαμηλότερο σκορ από όλα, δείχνοντας μας τη δυσκολία διαχωρισμού τετράποδων με παρόμοια χαρακτηριστικά.

Οπτικοποιώντας τα αποτελέσματα, μπορούμε να εντοπίσουμε σε ποιες κλάσεις μπερδεύει με ποιες και να διακρίνουμε καλύτερα την δυσκολία στα τετράποδα.



3.3.2 Αλγόριθμος k-Nearest Neighbors (k-NN)

Ο αλγόριθμος k-NN, ο οποίος απέδωσε τα χαμηλότερα αποτελέσματα Με χρήση μόνο HOG η ακρίβεια ήταν **47.95%**, ενώ με την προσθήκη χρώματος ανέβηκε, οριακά, στο **49.62%**.

Ουσιαστικά, ο k-NN συγκρίνει τις εικόνες “τυφλά”, κοιτάζοντας απλώς πόσο μοιάζουν τα νούμερα (pixels) μεταξύ τους. Δεν μπορεί να καταλάβει το περιεχόμενο της εικόνας. Έτσι, αν δύο εικόνες έχουν παρόμοιο φόντο (π.χ. πολύ μπλε χρώμα), ο αλγόριθμος νομίζει ότι απεικονίζουν το ίδιο αντικείμενο, ακόμα και αν η μία δείχνει αεροπλάνο και η άλλη πλοίο.

Αξιοσημείωτη Παρατήρηση: Όπως φαίνεται στον παρακάτω πίνακα, το μοντέλο παρουσιάζει ακραία συμπεριφορά σε συγκεκριμένες κλάσεις. Για παράδειγμα, στην κλάση **'Frog'** έχει τεράστιο **Recall (83%)** αλλά πολύ χαμηλό Precision (35%). Αυτό σημαίνει ότι το μοντέλο τείνει να ταξινομεί ως "βάτραχο" οτιδήποτε έχει έντονο πράσινο χρώμα, μπερδεύοντάς το με άλλες κλάσεις. Αντίθετα, αδυνατεί πλήρως να εντοπίσει τα **Πουλιά (Recall 16%)**, πιθανότατα λόγω της μεγάλης ποικιλίας στο φόντο (ουρανός, δέντρα, έδαφος).

Κλάση	Precision	Recall	Σχόλιο
Frog	0.35	**0.83**	"Βλέπει" βατράχους παντού (λόγω χρώματος), κάνοντας πολλά λάθη.
Airplane	**0.82**	0.45	Όταν προβλέπει αεροπλάνο είναι σωστό, αλλά χάνει τα μισά.
Bird	0.74	**0.16**	Αποτυγχάνει σχεδόν πλήρως να τα εντοπίσει.
Cat	0.45	**0.21**	Εξαιρετικά χαμηλή αναγνώριση.

3.3.3 Αλγόριθμος Random Forest

Για τον αλγόριθμο Random Forest πραγματοποιήθηκε συγκριτική μελέτη δύο προσεγγίσεων: εκπαίδευση στα μειωμένα χαρακτηριστικά μέσω PCA και εκπαίδευση στο αρχικό πλήθος χαρακτηριστικών.

Μέθοδος Εκπαίδευσης	HOG Only	HOG + Color (Combined)
Με χρήση PCA	49.12%	49.50%
Χωρίς PCA	**50.38%**	**50.90%**

Παρατηρήθηκε ότι η χρήση PCA μείωσε ελάχιστα την ακρίβεια του αλγορίθμου. Επιβεβαιώνοντας ότι ο αλγόριθμος λειτουργεί καλύτερα στα ακατέργαστα χαρακτηριστικά ακόμα και αν υπάρχει θόρυβος σε αυτά.

Συνεπώς επιλέχθηκε η εκπαίδευση στα αρχικά χαρακτηριστικά (Raw Features: HOG + Color χωρίς PCA), καθώς τα πειράματα έδειξαν ότι η μείωση διαστάσεων επηρέασε αρνητικά την απόδοση.

Πραγματοποιήθηκε αναζήτηση των βέλτιστων υπερπαραμέτρων μέσω **Cross-Validation (CV=3)** στο σύνολο **HOG +Color χωρις PCA**, εξετάζοντας το ακόλουθο εύρος τιμών:

- **n_estimators (Αριθμός δέντρων):** 50, 100, 200
- **max_depth:** None, 10, 20
- **min_samples_split:** 2, 4, 10
- **min_samples_leaf:** 1, 4

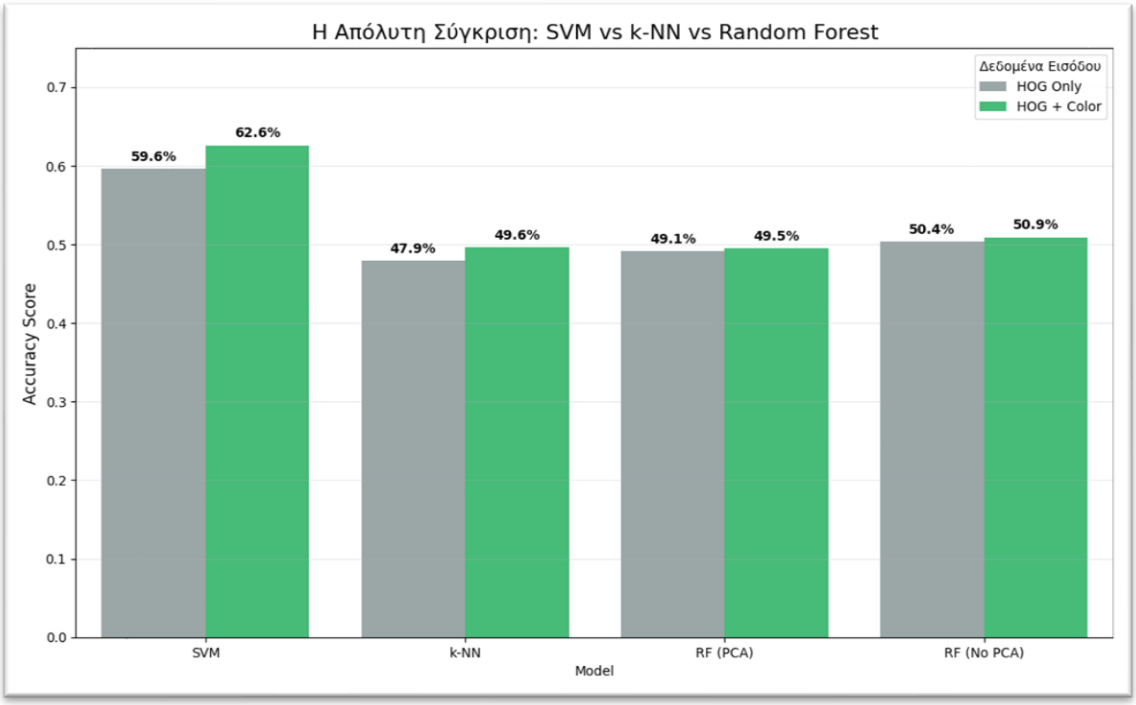
Το βέλτιστο μοντέλο προέκυψε με τις ρυθμίσεις: **n_estimators=200**, **max_depth=None** και **min_samples_split=4**.

Η αύξηση των δέντρων σε 200 προσέφερε μεγαλύτερη σταθερότητα και μείωσε τη διακύμανση (variance) του μοντέλου. Η επιλογή **max_depth=None** επέτρεψε στα δέντρα να αναπτυχθούν πλήρως για να συλλάβουν την πολυπλοκότητα των χιλιάδων χαρακτηριστικών, ενώ η παράμετρος **min_samples_split=4** λειτούργησε ως δικλείδα ασφαλείας κατά του overfitting.

Παρόλο της υπερπαραμετροποιήσης και τις χρήσης των αρχικών χαρακτηριστικών, όπως φαίνεται στον παρακάτω πίνακα, η προσθήκη του χρώματος δεν λειτούργησε ευεργετικά για όλες τις κλάσεις.

Κατηγορία	Precision	Recall	F1-Score	Παρατηρήσεις
Automobile	0.53	**0.68**	**0.60**	Η πιο "εύκολη" κλάση για το μοντέλο.
Truck	0.54	0.65	**0.59**	Υψηλή επίδοση, παρόμοια με τα αυτοκίνητα.
Frog	0.50	0.61	**0.55**	Καλή ανάκληση (Recall), αλλά με πολλά ψευδώς θετικά.
Bird	0.54	0.31	**0.39**	Εξαιρετικά χαμηλό Recall (χάνει το 70% των πτηνών).
Cat	**0.33**	**0.20**	**0.25**	**Η χειρότερη επίδοση.** Η προσθήκη χρώματος αύξησε τη σύγχυση (μειώθηκε από το 0.29 του HOG-only).

3.4 Τελικά συμπεράσματα



Συνοψίζοντας τα αποτελέσματα με βάση το παραπάνω διάγραμμα, παρατηρούμε ότι ο **συνδυασμός της γεωμετρίας των εικόνων** (HOG) με το **χρώμα** τους **βελτίωσε την απόδοση** όλων των μοντέλων. Ο ρόλος της PCA για αλγορίθμους όπως ο SVM είναι καταλυτικός, ενώ σε αλγορίθμους που μπορούν να διαχειριστούν την ακατέργαστη πληροφορία, όπως ο Random Forest, λειτουργεί αρνητικά.

Τα αποτελέσματα αυτά συμβαδίζουν με αντίστοιχες μελέτες στη βιβλιογραφία [4], όπου η χρήση απλών χαρακτηριστικών HOG έδωσε παρόμοια ποσοστά ακρίβειας (περίπου 53%).

Με τη χρήση **κλασικών** μεθόδων μηχανικής μάθησης, η ακρίβεια φαίνεται να μην μπορεί να ανέβει πολύ παραπάνω από το 63%, καθώς οι αλγόριθμοι **συγχέονται** σε σημασιολογικά παρόμοιες κλάσεις (π.χ. γάτα vs σκύλος). Το 63% παραμένει ικανοποιητικό αναλογίζοντας ότι υπάρχουν 10 κλάσεις, παρόλα αυτά για την επίτευξη υψηλότερου ποσοστού ακρίβειας **προτείνεται** η χρήση αλγορίθμων Βαθιάς Μάθησης (Deep Learning), οι οποίοι εξάγουν αυτόματα τα βέλτιστα χαρακτηριστικά από τις εικόνες.

5. Βιβλιογραφία - Αναφορές

[1]. M. Mohri, A. M. Medina. Learning Algorithms for Second-Price Auctions with Reserve. Journal of Machine Learning Research 17 (2016): 1–25.

[2]. A. Krizhevsky. Learning Multiple Layers of Features from Tiny Images. Technical Report, University of Toronto, 2009 https://www.cs.toronto.edu/~kriz/learning-features-2009-TR.pdf

[3]. N. Dalal and B. Triggs. Histograms of Oriented Gradients for Human Detection. IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR), 2005. https://www.cs.toronto.edu/~kriz/cifar.html

[4]. F. O. Giuste and J. C. Vizcarra. *CIFAR-10 Image Classification Using Feature Ensembles*. arXiv preprint arXiv:2002.03846, 2020.